3 插值

3.1 插值+多项式估计

1 插值问题

- **线性插值（$n=1$）**

给定两点 $(x_0,y_0),(x_1,y_1)$，

定义基函数：

$$L_0(x)=\frac{x-x_1}{x_0-x_1},\quad L_1(x)=\frac{x-x_0}{x_1-x_0}$$

线性插值多项式：

$$\boxed{P_1(x)=f(x_0)L_0(x)+f(x_1)L_1(x)}$$

- **一般 Lagrange 基函数**

对 $n+1$ 个节点 $x_0,\dots,x_n$，定义

$$L_k(x)=\prod_{\substack{i=0\\i\neq k}}^{n}\frac{x-x_i}{x_k-x_i}$$

性质：

$$L_k(x_i)=\begin{cases}1, & i=k\\0, & i\neq k\end{cases}$$

- **定理（Lagrange 插值公式）**

$$\boxed{P_n(x)=\sum_{k=0}^{n}f(x_k)L_k(x)}$$

2 插值误差理论

- **插值余项公式**
  若 $f\in C^{n+1}[a,b]$，则

$$\boxed{f(x)-P_n(x)=\frac{f^{(n+1)}(\xi(x))}{(n+1)!}\prod_{i=0}^{n}(x-x_i)}$$

  其中 $\xi(x)\in(a,b)$，一般未知。
- **误差上界估计**
  若

$$\max_{[a,b]}|f^{(n+1)}(x)|\le M_{n+1}$$

  则

$$\boxed{|R_n(x)|\le\frac{M_{n+1}}{(n+1)!}\left|\prod_{i=0}^{n}(x-x_i)\right|}$$

- 误差与 **节点分布** 强相关
- 当 $x\in[x_0,x_n]$ 内时误差较小
- 若 f 本身是 $\le n$ 次多项式：

$$\boxed{P_n(x) \equiv f(x)}$$

3.2数据逼近与 Neville 方法（Data Approximation）

1 插值计算的实际问题

Lagrange 插值的不足：

- 误差项不便于直接计算
- 已算出的低阶插值结果 **不能复用**
- 计算 $P_{n+1}(x)$ 需要全部重来
  👉 目标：
  构造一种递推方法，使高阶插值能复用低阶结果

2 定理（Neville 递推公式，Theorem 3.5）

let x_j and x_i be two distinct numbers

$$P(x) = \frac{(x - x_j)P_{0,1,\ldots,j-1,j+1,\ldots,k}(x) - (x - x_i)P_{0,1,\ldots,i-1,i+1,\ldots,k}(x)}{x_i - x_j}$$

3 Neville 递推表结构

构造如下三角表：

x_0	P_0				
x_1	P_1	$P_{0,1}$			
x_2	P_2	$P_{1,2}$	$P_{0,1,2}$		
x_3	P_3	$P_{2,3}$	$P_{1,2,3}$	$P_{0,1,2,3}$	
x_4	P_4	$P_{3,4}$	$P_{2,3,4}$	$P_{1,2,3,4}$	$P_{0,1,2,3,4}$

4 Neville 方法的优点

- 不需要写出插值多项式
- 计算过程稳定、清晰
- 易于逐步提高插值阶数
- 特别适合 **只关心某一点 x 的函数值**

3.3 差商+Newton 插值法

1 差商的定义（Divided Differences）

- 零阶差商，给定节点 $x_0, x_1, \ldots, x_n$，

$$f[x_i] = f(x_i)$$

- 一阶差商

$$f[x_i, x_{i+1}] = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i}$$

- 高阶差商（递推定义）对 $k \geq 1$，

$$f[x_i, \ldots, x_{i+k}] = \frac{f[x_{i+1}, \ldots, x_{i+k}] f[x_i, \ldots, x_{i+k-1}]}{x_{i+k} - x_i}$$

2 差商表（Divided Difference Table）

差商可用三角表形式生成：

- 第 0 列：$f[x_i]$
- 第 1 列：$f[x_i, x_{i+1}]$
- 第 2 列：$f[x_i, x_{i+1}, x_{i+2}]$
- $\ldots$

  📌 计算特点：
- 每一阶差商只依赖前一阶
- 可逐步加入新节点

3 Newton 插值多项式（核心公式）

利用差商，可将插值多项式写成 **Newton 形式**：

$$\boxed{\begin{aligned} P_n(x) = & f[x_0] + f[x_0, x_1](x - x_0) \\ & + f[x_0, x_1, x_2](x - x_0)(x - x_1) \\ & + \cdots \\ & + f[x_0, \ldots, x_n] \prod_{k=0}^{n-1} (x - x_k) \end{aligned}}$$

- 插值多项式 **逐项累加**
- 增加新节点只需添加一项
- 差商表可重复利用
- 比 Lagrange 形式更适合数值计算

4 定理（差商和函数导数之间关系，Theorem 3.6）

Suppose that $f \in C^n[a, b]$ and $x_0, x_1, ..., x_n$ are distinct numbers in $[a, b]$. Then a number ξ exists in (a, b) with

$$f[x_0, x_1, ..., x_n] = \frac{f^{(n)}(\xi)}{n!}$$

5 等距节点情形与差分

若节点等距：$h = x_{i+1} - x_i, i = 0, 1, ..., n-1$ and let $x = x_0 + sh$. Then the difference $x - x_i$ is $(s - i)h$.

$$P_n(x) = P(x_0 + sh)$$

$$= f[x_0] + shf[x_0, x_1] + s(s-1)h^2 f[x_0, x_1, x_2] + \cdots$$

$$+ s(s-1)\cdots(s-n+1)h^n f[x_0, x_1, ..., x_n]$$

$$= f[x_0] + \sum_{k=1}^{n} s(s-1)\cdots(s-k+1)h^k f[x_0, x_1, ..., x_k].$$

使用二项系数符号

$$\boxed{P_n(x) = P_n(x_0 + sh) = f[x_0] + \sum_{k=1}^{n} \binom{s}{k} k! h^k f[x_0, x_1, ..., x_k]}$$

5.1 Newton 前向差分插值公式（Forward Differences）

定义前向差分算子：$\Delta f(x_i) = f(x_{i+1}) - f(x_i)$
高阶前向差分：$\Delta^k f(x_i) = \Delta(\Delta^{k-1} f(x_i))$
令$s = \frac{x - x_0}{h}$
则

$$\boxed{\begin{aligned} P_n(x) = f(x_0) + s\Delta f(x_0) + \frac{s(s-1)}{2!}\Delta^2 f(x_0) \\ + \cdots + \frac{s(s-1)\cdots(s-n+1)}{n!}\Delta^n f(x_0) \end{aligned}}$$

适用场景：x 靠近 x_0；等距节点数据表

5.2 Newton 后向差分插值公式（Backward Differences）

定义后向差分：$\nabla f(x_i) = f(x_i) - f(x_{i-1})$
令$s = \frac{x - x_n}{h}$
则

$$\boxed{\begin{aligned} P_n(x) = f(x_n) + s\nabla f(x_n) + \frac{s(s+1)}{2!}\nabla^2 f(x_n) \\ + \cdots + \frac{s(s+1)\cdots(s+n-1)}{n!}\nabla^n f(x_n) \end{aligned}}$$

适用场景：x 靠近区间右端点 x_n

5.3 Newton 中心差分插值公式（Centered Differences）

$$\boxed{\begin{aligned} P_n(x) = P_{2m+1}(x) = f[x_0] + \frac{sn}{2}(f[x_{-1}, x_0] + f[x_0, x_1]) + s^2 h^2 f[x_{-1}, x_0, x_1] \\ + \frac{s(s^2-1)h^3}{2}(f[x_{-2}, x_{-1}, x_0, x_1] + f[x_{-1}, x_0, x_1, x_2]) + \cdots \\ + s^2(s^2-1)(s^2-4)\cdots(s^2-(m-1)^2)h^{2m} f[x_{-m}, \ldots, x_m] \\ + \frac{s\left(s^2-1\right)\cdots\left(s^2-m^2\right)h^{2m+1}}{2}(f[x_{-m-1}, ..., x_m] + f[x_{-m}, ..., x_{m+1}]), \end{aligned}}$$

x	$f(x)$	First divided differences	Second divided differences	Third divided differences	Fourth divided differences
x_{-2}	$f[x_{-2}]$				
		$f[x_{-2},x_{-1}]$			
x_{-1}	$f[x_{-1}]$		$f[x_{-2},x_{-1},x_0]$		
		$\underline{f[x_{-1},x_0]}$		$\underline{f[x_{-2},x_{-1},x_0,x_1]}$	
x_0	$\underline{f[x_0]}$		$\underline{f[x_{-1},x_0,x_1]}$		$\underline{f[x_{-2},x_{-1},x_0,x_1,x_2]}$
		$\underline{f[x_0,x_1]}$		$\underline{f[x_{-1},x_0,x_1,x_2]}$	
x_1	$f[x_1]$		$f[x_0,x_1,x_2]$		
		$f[x_1,x_2]$			
x_2	$f[x_2]$				

如果 n=2m+1 是奇数。如果n=2m为偶数，我们使用相同公式但删除最后一行。该公式所用的条目在表3.13中有划线。

- 差商是 Newton 插值的核心工具
- Newton 形式比 Lagrange 形式更适合计算
- 等距节点下可进一步简化为差分公式
- 前向 / 后向公式取决于插值点位置

3.4 Hermite 插值（Hermite Interpolation）

1 Hermite 插值问题描述

- 引入 在前面的插值方法中（Lagrange / Newton）：只使用了函数值 $f(x_i)$。忽略了函数在节点处的导数信息

👉 若已知：

$$f(x_i), \quad f'(x_i)$$

则可以构造更高精度的插值多项式

- **Hermite的表示**
  给定节点$x_0, x_1, \ldots, x_n$
  并已知数据：$f(x_i), \quad f'(x_i), \quad i = 0, 1, \ldots, n$
  求一个多项式 $H(x)$，使

$$\begin{cases} H(x_i) = f(x_i), \\ H'(x_i) = f'(x_i), \end{cases} \quad i = 0, 1, \ldots, n$$

- **多项式次数与唯一性**

共 $2(n+1)$ 个条件
可构造次数 $\leq 2n+1$ 的多项式

定理（存在性与唯一性）存在唯一的 Hermite 插值多项式 $H_{2n+1}(x)$

- **Hermite 插值的基本思想**
  核心思想：将每个节点重复一次。将导数条件转化为差商极限

📌 在差商表中：

- x_i 出现两次

- 对角差商引入导数信息

2 Hermite 插值多项式（显示形式）

若 $f \in C^1[a,b]$，且 $x_0, x_1, \ldots, x_n \in [a,b]$ 两两不同，则存在唯一一个次数不超过 $2n+1$ 的多项式，它在节点 $x_0, x_1, \ldots, x_n$ 处同时与 f 及其导数 f' 相符合，该多项式称为 Hermite 插值多项式，其表达式为

$$\boxed{H_{2n+1}(x) = \sum_{j=0}^{n} f(x_j) H_{n,j}(x) + \sum_{j=0}^{n} f'(x_j) \widehat{H}_{n,j}(x)}$$

其中，设 $L_{n,j}(x)$ 表示第 j 个拉格朗日插值基函数（次数为 n），则

$$H_{n,j}(x) = [1 - 2(x - x_j) L'_{n,j}(x_j)] L^2_{n,j}(x) \text{ and } \widehat{H}_{n,j}(x) = (x - x_j) L^2_{n,j}(x).$$

此外，若 $f \in C^{2n+2}[a,b]$，则 Hermite 插值的误差可表示为

$$f(x) = H_{2n+1}(x) + \frac{(x-x_0)^2 \ldots (x-x_n)^2}{(2n+2)!} f^{(2n+2)}(\xi(x))$$

其中 $\xi(x)$ 为区间 (a,b) 内某个（一般未知的）点。

3 Hermite 插值多项式（Newton 形式）

对于重复节点 x_i：

- 零阶差商：$f[z_2 i] = f[z_2 i + 1] = f(x_i)$
- 一阶差商：
  - 若$z_i = z_{i+1}$: $f[z_i, z_{i+1}] = f'(x_i)$
  - 否则：正常差商公式
- 其余差商按标准递推：

$$\boxed{\begin{aligned} H_{2n+1}(x) = {} & f[z_0] + f[z_0, z_1](x - z_0) \\ & + f[z_0, z_1, z_2](x - z_0)(x - z_1) \\ & + \cdots \\ & + f[z_0, \ldots, z_{2n+1}] \prod_{k=0}^{2n} (x - z_k) \end{aligned}}$$

$$\boxed{H_{2n+1}(x) = f[z_0] + \sum_{k=1}^{2n+1} f[z_0, \cdots, z_k](x - z_0)(x - z_1) \cdots (x - z_{k-1})}$$

📌 特点：

- 结构与 Newton 插值完全一致
- 系数来自 **Hermite 差商表**

4 定理（Hermite 插值的差商表示，Theorem 3.9）

设 $H(x)$ 为 Hermite 插值多项式，则：

$$\boxed{H[x_0, x_0, \ldots, x_k, x_k] = \frac{f^{(k)}(\xi)}{k!}}$$

其中 ξ 位于插值区间内。

👉 说明：

- Hermite 插值仍可进行误差分析
- 形式与 Newton 插值误差高度类似

5 Hermite 插值的数值分析意义

- 利用导数信息，提高逼近精度
- 比 Lagrange / Newton 插值更“昂贵”
- 适合函数及其导数可获得的情形
- 常用于：
  - 轨道拟合
  - 曲线光滑连接
  - 数值微分与高精度逼近
  - 本质是 **带重复节点的 Newton 插值**

3.5 三次样条插值（Cubic Spline Interpolation）

1 引入：为什么不用高次插值多项式?

在前面的插值方法中，我们使用**单个多项式**在整个区间 $[a,b]$ 上逼近函数。
📌 问题：

- 当插值次数较高时，多项式容易出现**剧烈振荡**
- 局部的小扰动可能导致整体的大波动（Runge 现象）
  👉 改进思路：
  将区间划分为若干子区间，在每个子区间上分别构造低次多项式
  这种方法称为 **分段多项式逼近（piecewise-polynomial approximation）**

2 分段线性插值（Piecewise Linear Interpolation）

若函数 $I(x)$ 满足:

$$I(x) \in C[a,b]$$

$$I(x_k) = y_k, \quad k = 0,1,\dots,n$$

$I(x)$ 在每个子区间 $[x_k, x_{k+1}]$ 上是一次多项式
则称 $I(x)$ 为分段线性插值函数 (piecewise linear interpolating polynomial)。

$$I(x) = \sum_{j=0}^{n} y_j l_j(x)$$

$$l_j(x) = \begin{cases} \frac{x-x_{j-1}}{x_j-x_{j-1}}, x_{j-1} \le x \le x_j & (j \ne 0) \\ \frac{x-x_{j+1}}{x_j-x_{j+1}}, x_j \le x \le x_{j+1} & (j \ne n) \\ 0, & \text{others} \end{cases}$$

3 分段 Hermite 三次插值

(1) $I(x) \in C^1[a,b]$

(2) $I(x_k) = y_k, \quad I'(x_k) = m_k$

(3) 在每个子区间 $[x_k, x_{k+1}]$ 上，$I(x)$ 是一个三次多项式。我们称这样的 $I(x)$ 为 分段 Hermite 三次插值多项式（piecewise Hermite cubic interpolating polynomial）

$$
\begin{aligned}
I(x) &= \sum_{j=0}^{n}[y_j\alpha_j\,(x) + m_j\beta_j(x)] \\
\alpha_j(x) &= \begin{cases} \left(\frac{x-x_{j-1}}{x_j-x_{j-1}}\right)^2(1+2\frac{x-x_j}{x_{j-1}-x_j}), x_{j-1}\le x\le x_j & (j\ne 0) \\ \left(\frac{x-x_{j+1}}{x_j-x_{j+1}}\right)^2(1+2\frac{x-x_j}{x_{j+1}-x_j}), x_j\le x\le x_{j+1} & (j\ne n) \\ 0, & \text{others} \end{cases} \\
\beta_j(x) &= \begin{cases} \left(\frac{x-x_{j-1}}{x_j-x_{j-1}}\right)^2(x-x_j), x_{j-1}\le x\le x_j & (j\ne 0) \\ \left(\frac{x-x_{j+1}}{x_j-x_{j+1}}\right)^2(x-x_j), x_j\le x\le x_{j+1} & (j\ne n) \\ 0, & \text{others} \end{cases}
\end{aligned}
$$

- **误差分析**

若函数 $f(x)\in C^4[a,b]$，并且已知函数值与导数数据表

$$(x_i,\,y_i,\,m_i),\quad i=0,1,\ldots,n,$$

则对任意 $x\in[a,b]$，分段 Hermite 三次插值多项式 $I(x)$ 的误差满足

$$|f(x)-I(x)|\le\frac{h^4}{384}\max_{a\le s\le b}|f^{(4)}(s)|,\qquad x\in[a,b].$$

4 三次样条插值（Cubic Spline）

给定节点

$$a=x_0<x_1<\cdots<x_n=b$$

称函数 $S(x)$ 为 **三次样条插值函数**，若满足：

1. 在每个区间 $[x_i,x_{i+1}]$ 上，

$$S_i(x)=a_i+b_i(x-x_i)+c_i(x-x_i)^2+d_i(x-x_i)^3$$

2. 插值条件：

$$S_j(x_j)=f(x_j),S_j(x_j+1)=f(x_j+1)\quad i=0,1,\ldots,n$$

3. 函数连续：

$$S_j+1(x_j+1)=S_j(x_j+1),\quad i=0,1,\ldots,n$$

4. 一阶导连续：

$$S_j'(x_{j+1})=S_{j+1}'(x_{j+1})$$

5. 二阶导连续：

$$S_j''(x_{j+1})=S_{j+1}''(x_{j+1})$$

6. 边界条件（必须二选一）
   需满足以下两类边界条件之一：

- **自然（自由）边界条件** $S''(x_0)=0,\quad S''(x_n)=0$（称为自然三次样条，natural spline）
- **夹持边界条件** $S'(x_0)=f'(x_0),\quad S'(x_n)=f'(x_n)$（称为夹持三次样条，clamped spline）

6 三次样条的构造（Construction）

4 数值微分与积分

4.1 数值微分（Numerical Differentiation）

1 引入：为什么需要数值微分？

👉 目标：仅利用离散函数值，近似计算导数（如 $f'(x_0)$、$f''(x_0)$）。

- **插值思想**：构造插值多项式 $P(x)$ 逼近 $f(x)$，再用 $P'(x)$ 逼近 $f'(x)$；
- **Taylor 思想**：对 $f(x_0 \pm h)$ 展开并消去高阶项，得到差分形式。

2 两点公式：前向/后向差分（Forward/Backward Difference）

2.1 线性插值（两点）与误差项

取 $x_1 = x_0 + h$（$h \neq 0$），对 $f \in C^2[a,b]$，线性 Lagrange 插值带余项为

$$f(x) = P_{0,1}(x) + \frac{(x-x_0)(x-x_1)}{2!} f''(\xi(x)), \quad \xi(x) \in (x_0, x_1).$$

对上式求导并在 $x = x_0$ 处代入，可得

$$\boxed{f'(x_0) = \frac{f(x_0+h) - f(x_0)}{h} - \frac{h}{2} f''(\xi)} \tag{4.1}$$

其中 ξ 位于 x_0 与 $x_0 + h$ 之间。

因此（舍去误差项）得到**前向差分/后向差分统一写法**：
$$

\boxed{
f'(x_0)\approx \frac{f(x_0+h)-f(x_0)}{h}
}
$$

- 若 $h > 0$：**前向差分（forward difference）**
- 若 $h < 0$：**后向差分（backward difference）**

2.2 截断误差上界（Truncation Error Bound）

若在区间 (x_0, x_0+h) 上有 $|f''(x)| \leq M$，则由 (4.1) 得

$$\boxed{\left| f'(x_0) - \frac{f(x_0+h) - f(x_0)}{h} \right| \leq \frac{M|h|}{2}}$$

📌 误差阶：$O(h)$。

3 一般 $(n+1)$ 点导数公式（General $(n+1)$-point Formula）

设 $x_0, x_1, \ldots, x_n$ 为区间 I 上互不相同的节点，$f \in C^{n+1}(I)$。
Lagrange 插值带余项：

$$f(x) = \sum_{k=0}^{n} f(x_k) L_k(x) + \frac{(x-x_0)(x-x_1)\cdots(x-x_n)}{(n+1)!} f^{(n+1)}(\xi(x)).$$

对其求导，并在节点 $x = x_j$ 处代入（此时含 $D_x f^{(n+1)}(\xi(x))$ 的项会消失），得到：

$$\boxed{f'(x_j) = \sum_{k=0}^{n} f(x_k)\, L_k'(x_j) + \frac{f^{(n+1)}(\xi(x_j))}{(n+1)!} \prod_{\substack{k=0 \\ k\neq j}}^{n} (x_j - x_k)} \tag{4.2}$$

📌 含义：导数近似公式可以系统地由插值多项式求导得到；误差项与高阶导数有关。

4 三点公式（Three-Point Formulas，等距节点）

下面开始**默认节点等距**（常见数据表情形）：

$$x_1 = x_0 + h, \quad x_2 = x_0 + 2h.$$

4.1 三点端点公式（Endpoint Formula）

$$\boxed{f'(x_0) = \frac{-3f(x_0) + 4f(x_0+h) - f(x_0+2h)}{2h} + \frac{h^2}{3} f^{(3)}(\xi_0)} \tag{4.4}$$

其中 ξ_0 位于 x_0 与 $x_0 + 2h$ 之间。

- 近似（舍去误差项）：

$$\boxed{f'(x_0) \approx \frac{-3f(x_0) + 4f(x_0+h) - f(x_0+2h)}{2h}}$$

  📌 误差阶：$O(h^2)$
  📌 使用场景：靠近区间端点（只能用一侧数据时很有用）

4.2 三点中点公式（Midpoint / Centered Difference）

$$\boxed{f'(x_0) = \frac{f(x_0+h) - f(x_0-h)}{2h} - \frac{h^2}{6} f^{(3)}(\xi_1)} \tag{4.5}$$

其中 ξ_1 位于 $(x_0 - h,\ x_0 + h)$。

- 近似（舍去误差项）：

$$\boxed{f'(x_0) \approx \frac{f(x_0+h) - f(x_0-h)}{2h}}$$

  📌 误差阶：$O(h^2)$（通常比两点公式高一阶）
  📌 特点：利用 x_0 两侧数据，往往比端点公式更准（同阶但常数更小），且只需两次函数值。

5 五点公式（Five-Point Formulas）

五点公式通常精度更高，但需要更多数据点。

5.1 五点中点公式（Five-Point Midpoint）

$$\boxed{f'(x_0) = \frac{f(x_0-2h) - 8f(x_0-h) + 8f(x_0+h) - f(x_0+2h)}{12h} + \frac{h^4}{30} f^{(5)}(\xi)} \tag{4.6}$$

其中 $\xi \in (x_0 - 2h,\ x_0 + 2h)$。

📌 误差阶：$O(h^4)$（显著更高精度）

5.2 五点端点公式（Five-Point Endpoint）

$$\boxed{\begin{aligned} f'(x_0) = &\frac{-25f(x_0) + 48f(x_0+h) - 36f(x_0+2h) + 16f(x_0+3h) - 3f(x_0+4h)}{12h} \\ &+ \frac{h^4}{5} f^{(5)}(\xi) \end{aligned}} \tag{4.7}$$

其中 $\xi \in (x_0,\ x_0 + 4h)$。

📌 误差阶：$O(h^4)$
📌 适用：端点附近需要高阶精度时（如夹持样条等应用中常见）

6 二阶导数的数值近似：二阶中点公式（Second Derivative Midpoint）

对 $f(x_0 \pm h)$ 作 Taylor 展开并相加，可消去一阶导项，得到二阶导近似：

$$\boxed{f''(x_0) = \frac{f(x_0-h) - 2f(x_0) + f(x_0+h)}{h^2} - \frac{h^2}{12} f^{(4)}(\xi)} \tag{4.9}$$

其中 $\xi \in (x_0 - h,\ x_0 + h)$。

📌 若 $f^{(4)}$ 在 $[x_0 - h, x_0 + h]$ 连续且有界，则误差阶为 $O(h^2)$。

7 舍入误差与不稳定性（Round-off Error Instability）

数值微分特别容易受舍入误差影响，因为公式中要除以 h（甚至 h^2、h^3...）。

以三点中点公式 (4.5) 为例：

$$f'(x_0) \approx \frac{f(x_0+h) - f(x_0-h)}{2h}.$$

若计算 $f(x_0 \pm h)$ 时存在舍入误差 $e(x_0 \pm h)$，则总误差由两部分组成：

- 舍入误差项：$\dfrac{e(x_0+h) - e(x_0-h)}{2h}$
- 截断误差项：$\dfrac{h^2}{6} f^{(3)}(\xi_1)$

若 $|e(x_0 \pm h)| \le \varepsilon$ 且 $|f^{(3)}(x)| \le M$，则

$$\boxed{|\text{总误差}| \le \frac{\varepsilon}{h} + \frac{h^2}{6} M}$$

📌 关键矛盾：

- h 变小 ⇒ 截断误差 $\sim h^2$ 下降
- 但 h 变小 ⇒ 舍入误差 $\sim \varepsilon/h$ 上升（会“爆炸”）

因此：**减小步长不一定更好**，数值微分在数值上是**不稳定**的。

7.1 最优步长（理论上）

对

$$e(h) = \frac{\varepsilon}{h} + \frac{h^2}{6} M$$

求最小值，可得最优步长满足

$$\boxed{h = \sqrt[3]{\frac{3\varepsilon}{M}}}$$

12 方法比较与总结（常用结论）

方法	近似形式	误差阶	适用场景
两点前/后向差分	$\dfrac{f(x_0+h)-f(x_0)}{h}$	$O(h)$	数据少；端点附近
三点端点	$\dfrac{-3f_0+4f_1-f_2}{2h}$	$O(h^2)$	端点附近且想更准
三点中点	$\dfrac{f(x_0+h)-f(x_0-h)}{2h}$	$O(h^2)$	内点；常用且稳定性更好
五点中点	$\dfrac{f_{-2}-8f_{-1}+8f_1-f_2}{12h}$	$O(h^4)$	数据允许时高精度
二阶导中点	$\dfrac{f_{-1}-2f_0+f_1}{h^2}$	$O(h^2)$	近似 $f''(x_0)$

📌 核心提醒：
数值微分存在“截断误差 vs 舍入误差”的矛盾，h 不能无限小；实际计算要警惕不稳定性。

4.2 理查森外推（Richardson Extrapolation）

1 引入：为什么要外推？

理查森外推的目标是：**用低阶近似公式的结果，通过“巧妙线性组合”，在几乎不增加计算量的情况下得到更高精度的结果**
外推可用的关键前提是：我们知道某个近似公式的误差项具有**可预测的形式**，通常与步长参数 h 有关。

2 基本设定：误差展开的“模板”

设 M 是我们想求的未知常数（例如某个积分值、某个导数值），并且对每个 $h \neq 0$ 我们都能算出一个近似 $N_1(h)$，满足截断误差可展开为

$$M - N_1(h) = K_1 h + K_2 h^2 + K_3 h^3 + \cdots$$

等价写成（Lecture 里记为 (4.10)）：

$$\boxed{M = N_1(h) + K_1 h + K_2 h^2 + K_3 h^3 + \cdots} \tag{4.10}$$

将 h 替换为 $h/2$（Lecture 里记为 (4.11)）：

$$\boxed{M = N_1\left(\frac{h}{2}\right) + K_1\frac{h}{2} + K_2\frac{h^2}{4} + K_3\frac{h^3}{8} + \cdots} \tag{4.11}$$

3 核心思想：消去主误差项（以 $O(h)$ 为例）

对 (4.11) 乘以 2 再减去 (4.10)，可以把 $K_1 h$ 这一项消掉：

$$2M - M = 2N_1\left(\frac{h}{2}\right) - N_1(h) + \left(K_2\frac{h^2}{2} - K_2 h^2\right) + \cdots$$

得到新的近似

$$\boxed{N_2(h) = 2N_1\left(\frac{h}{2}\right) - N_1(h)}$$

并且它满足（Lecture 里对应 (4.13) 的思想）：

$$\boxed{M - N_2(h) = O(h^2)}$$

📌 结论：

- 原来 $N_1(h)$ 的主误差是 $O(h)$
- 外推后 $N_2(h)$ 的主误差提升到 $O(h^2)$

4 更一般的外推条件（适用范围）

外推并不要求一定是整数次幂，只要误差有分层结构即可：

$$\boxed{M = N_1(h) + \sum_{j=1}^{m-1} K_j h^{\alpha_j} + O(h^{\alpha_m}), \quad \alpha_1 < \alpha_2 < \cdots < \alpha_m}$$

外推的本质：**用不同步长的结果做线性组合，逐级消去最低阶误差项。**

5 最常见、最“好用”的情形：误差只含偶次幂

很多重要公式（尤其是**对称/中心**结构的公式）误差只含偶次幂：

$$\boxed{M = N_1(h) + K_1 h^2 + K_2 h^4 + K_3 h^6 + \cdots} \tag{4.14}$$

📌 为什么更有效？
因为只要用 h 与 $h/2$，就能把 h^2 项消掉，直接从 $O(h^2)$ 跳到 $O(h^4)$，再跳到 $O(h^6)$ .....
而计算代价几乎只是“重复算几个更小步长的 N_1”。

6 偶次幂情形下的外推公式（最重要结论）

由 (4.14) 出发，把 $h \to h/2$ 后再乘 4 并相减，可消去 h^2 项，得到

6.1 从 $O(h^2)$ 提升到 $O(h^4)$

$$\boxed{N_2(h) = \frac{4N_1\left(\frac{h}{2}\right) - N_1(h)}{3}} \tag{4.15}$$

6.2 从 $O(h^4)$ 提升到 $O(h^6)$

继续同样思路，可得

$$\boxed{N_3(h) = \frac{16N_2\left(\frac{h}{2}\right) - N_2(h)}{15}}$$

6.3 通用递推公式（Lecture 4-2 给出的总公式）

对 $j = 2, 3, \ldots$:

$$\boxed{N_j(h) = N_{j-1}\left(\frac{h}{2}\right) + \frac{N_{j-1}\left(\frac{h}{2}\right) - N_{j-1}(h)}{4^{j-1} - 1}}$$

等价写法（更常用的“加权平均”形式）：

$$\boxed{N_j(h) = \frac{4^{j-1} N_{j-1}\left(\frac{h}{2}\right) - N_{j-1}(h)}{4^{j-1} - 1}}$$

7 Richardson 外推表（表格计算结构）

实际做题常用“三角表/外推表”组织计算（思想与 Romberg 表非常像）：

- 第 1 列：$N_1(h), N_1(h/2), N_1(h/4), \ldots$（原始低阶近似）
- 第 2 列：用上一节公式得到 $N_2(h), N_2(h/2), \ldots$
- 第 3 列：得到 $N_3(h), \ldots$

每往右一列，理论阶数提升 2（若是偶次幂情形）：

$$O(h^2) \;\to\; O(h^4) \;\to\; O(h^6) \;\to\; \cdots$$

📌 Lecture 的保守误差估计（对应 (4.16) 的口径）：
通常用**最后一条对角线相邻两项的差**作为误差/可靠性判断依据，例如：

$$\boxed{\text{可保守认为真值至少精确到 } |N_p(h) - N_{p+1}(h)| \text{ 这个量级}}$$

8 重要提醒：外推在数值微分中会受到舍入误差限制

虽然外推能把截断误差阶数快速提高，但在**数值微分**问题中：

- 外推表越往下，需要计算 $N_1(h/2^k)$（步长越来越小）
- 而微分公式本身要除以 h（甚至更高次幂）
- 因此 **舍入误差往往会被放大**，导致后面列/后面行不再稳定变好

📌 实用建议（Lecture 强调的经验做法）：

- 不要盲目追求更深层外推
- 重点观察**对角线收敛**情况
- 用相邻对角线结果的差来判断是否可信

9 本节小结（考试/作业常用要点）

1. 外推适用条件：误差可按 h 的幂次展开且阶次可分离。
2. 一般情形（含 h）：$N_2(h) = 2N_1(h/2) - N_1(h)$，阶数 $O(h^2)$.
3. 偶次幂情形（最常见最有效）：
   - $N_2(h) = \dfrac{4N_1(h/2) - N_1(h)}{3}$ （$O(h^4)$）
   - $N_3(h) = \dfrac{16N_2(h/2) - N_2(h)}{15}$ （$O(h^6)$）
   - 递推：$N_j(h) = \dfrac{4^{j-1}N_{j-1}(h/2) - N_{j-1}(h)}{4^{j-1} - 1}$
4. 数值微分场景：外推会让 h 变得极小，**可能被舍入误差主导**，要检查对角线是否真正收敛。

4.3 数值积分基础（Elements of Numerical Integration）

目标：用有限个函数值 $f(x_i)$ 构造 **求积公式（quadrature formula）** 来近似

$$I = \int_a^b f(x)\,dx.$$

1. 一般求积公式（Quadrature Formula）的统一框架

1.1 用插值多项式“代替”被积函数

取区间 $[a, b]$ 上互异节点

$$a \le x_0 < x_1 < \cdots < x_n \le b,$$

用 Lagrange 插值多项式 $P_n(x)$ 逼近 $f(x)$：

$$P_n(x) = \sum_{i=0}^{n} f(x_i)\,L_i(x), \quad L_i(x) = \prod_{\substack{j=0\\ j\neq i}}^{n} \frac{x - x_j}{x_i - x_j}.$$

对两边积分：

$$\int_a^b f(x)\,dx \approx \int_a^b P_n(x)\,dx = \sum_{i=0}^{n} f(x_i) \int_a^b L_i(x)\,dx.$$

1.2 权重（weights）与一般求积公式

定义权重

$$a_i = \int_a^b L_i(x)\,dx,$$

则得到通用求积形式

$$\boxed{\int_a^b f(x)\,dx \approx \sum_{i=0}^{n} a_i f(x_i)}$$

1.3 通用误差形式（来自插值余项）

插值余项写作

$$f(x) = P_n(x) + \frac{f^{(n+1)}(\xi(x))}{(n+1)!}\,\omega(x), \quad \omega(x) = \prod_{i=0}^{n}(x - x_i),$$

积分得到误差

$$\boxed{E(f) = \int_a^b f(x)\,dx - \sum_{i=0}^{n} a_i f(x_i) = \frac{1}{(n+1)!}\int_a^b \omega(x)\,f^{(n+1)}(\xi(x))\,dx}$$

其中每个 x 对应的 $\xi(x) \in (a,b)$（一般未知）。

2. 梯形法则（Trapezoidal Rule）

2.1 取一次插值（$n = 1$）

令

$$x_0 = a, \quad x_1 = b, \quad h = b - a.$$

用一次 Lagrange 多项式积分可得：

$$\boxed{\int_a^b f(x)\,dx = \frac{h}{2}\big[f(x_0) + f(x_1)\big] - \frac{h^3}{12} f''(\xi), \quad \xi \in (a,b)}$$

几何意义：用一个梯形的面积近似曲线下方面积。

2.2 精度直观

因为误差项含 f''，所以当 f 是一次多项式（$f'' \equiv 0$）时梯形法则 **完全精确**。

3. Simpson 法则（Simpson’s Rule）

3.1 取二次插值（$n = 2$）

令等距节点

$$x_0 = a, \quad x_1 = a + h, \quad x_2 = b, \quad h = \frac{b-a}{2}.$$

Simpson 公式（标准形式）：

$$\boxed{\int_{x_0}^{x_2} f(x)\,dx = \frac{h}{3}\big[f(x_0)+4f(x_1)+f(x_2)\big] - \frac{h^5}{90} f^{(4)}(\xi), \quad \xi \in (x_0, x_2)}$$

3.2 重要说明：为什么误差里出现 $f^{(4)}$？

- “直接对二次插值多项式积分”的推导，容易先得到一个含 $f^{(3)}$ 的 $O(h^4)$ 误差结构；
- 讲义用一个更聪明的方法：对 f 在中点 x_1 做 Taylor 展开并积分，
  再用 4.1 里二阶导数的差分近似（形如 $f''(x_1) \approx \frac{f(x_0)-2f(x_1)+f(x_2)}{h^2} + \cdots$）
  把误差“升级”为含 $f^{(4)}$ 的 $O(h^5)$ 形式，从而得到上面更常用的 Simpson 误差项。

> 这就是 4.3 与 4.1 的一个关键联系：**用数值微分公式辅助推导更高阶的数值积分误差表达**。

3.3 精度结论（很常考）

- Simpson 的误差项含 $f^{(4)}$，因此对所有次数 ≤ 3 的多项式都精确；
- 即 Simpson 的 **degree of precision = 3**（见后面 Definition 4.1）。

4. 精度（Precision）怎么定义与判断？

4.1 Definition 4.1（Degree of accuracy / precision）

一个求积公式的 **精度阶（degree of precision）** 是最大的正整数 n，使得该公式对

$$1, x, x^2, \ldots, x^n$$

都能给出 **完全精确** 的积分值。

记作：

$$\boxed{\text{precision} = n \iff \text{对所有 } x^k\ (k=0,\ldots,n) \text{ 精确，但对某个 } x^{n+1} \text{ 不精确}}$$

4.2 线性性质带来的“化简判断法”

积分与求和都是线性算子，因此判断精度只需检查多项式基 x^k 的表现。

4.3 典型结论

- 梯形法：precision $= 1$
- Simpson：precision $= 3$

5. Newton–Cotes 求积公式（核心框架）

Newton–Cotes 是“**等距节点插值 + 积分**”得到的一类求积公式，分两大类：

5.1 闭型（Closed Newton–Cotes）

包含端点 a, b。

(1) 节点与步长

$$x_i = x_0 + ih, \quad i = 0, 1, \ldots, n, \quad x_0 = a,\ x_n = b,\ h = \frac{b-a}{n}.$$

(2) 公式

$$\boxed{\int_a^b f(x)\,dx \approx \sum_{i=0}^{n} a_i f(x_i), \quad a_i = \int_a^b L_i(x)\,dx}$$

(3) Theorem 4.2（误差结构）

存在 $\xi \in (a,b)$ 使得：

- 若 n 为偶数且 $f \in C^{n+2}[a,b]$，则

$$\boxed{\int_a^b f(x)\,dx = \sum_{i=0}^{n} a_i f(x_i) + \frac{h^{n+3} f^{(n+2)}(\xi)}{(n+2)!} \int_0^n t^2(t-1)\cdots(t-n)\,dt}$$

- 若 n 为奇数且 $f \in C^{n+1}[a,b]$，则

$$\boxed{\int_a^b f(x)\,dx = \sum_{i=0}^{n} a_i f(x_i) + \frac{h^{n+2} f^{(n+1)}(\xi)}{(n+1)!} \int_0^n t(t-1)\cdots(t-n)\,dt}$$

(4) 一个很重要的结论（讲义强调）

- n 为 **偶数**：precision 反而是 $n+1$（比插值次数高 1）
- n 为 **奇数**：precision 只有 n

5.2 常见闭型 Newton–Cotes 公式（要背系数 + 看误差阶）

设节点等距，步长为 h。

(1) $n=1$：梯形法

$$\int_{x_0}^{x_1} f(x)\,dx = \frac{h}{2}\big[f(x_0)+f(x_1)\big] - \frac{h^3}{12} f''(\xi)$$

(2) $n=2$：Simpson

$$\int_{x_0}^{x_2} f(x)\,dx = \frac{h}{3}\big[f(x_0)+4f(x_1)+f(x_2)\big] - \frac{h^5}{90} f^{(4)}(\xi)$$

(3) $n=3$：Simpson 3/8 Rule

$$\int_{x_0}^{x_3} f(x)\,dx = \frac{3h}{8}\big[f(x_0)+3f(x_1)+3f(x_2)+f(x_3)\big] - \frac{3h^5}{80} f^{(4)}(\xi)$$

(4) $n=4$：五点闭型 Newton–Cotes

$$\int_{x_0}^{x_4} f(x)\,dx = \frac{2h}{45}\big[7f(x_0)+32f(x_1)+12f(x_2)+32f(x_3)+7f(x_4)\big] - \frac{8h^7}{945} f^{(6)}(\xi)$$

6. 开型（Open Newton–Cotes）

不包含端点 a,b 作为取样节点（节点在开区间 (a,b) 内）。

6.1 节点与步长

令

$$h = \frac{b-a}{n+2}, \quad x_0 = a+h,$$

则

$$x_i = x_0 + ih,\ i=0,1,\dots,n, \quad x_{-1}=a,\ x_{n+1}=b.$$

6.2 公式

$$\boxed{\int_a^b f(x)\,dx = \int_{x_{-1}}^{x_{n+1}} f(x)\,dx \approx \sum_{i=0}^{n} a_i f(x_i), \quad a_i = \int_a^b L_i(x)\,dx}$$

6.3 Theorem 4.3（开型误差结构）

存在 $\xi \in (a,b)$ 使得：

- 若 n 偶且 $f \in C^{n+2}[a,b]$，则

$$\boxed{\int_a^b f(x)\,dx = \sum_{i=0}^{n} a_i f(x_i) + \frac{h^{n+3} f^{(n+2)}(\xi)}{(n+2)!} \int_{-1}^{n+1} t^2(t-1)\cdots(t-n)\,dt}$$

- 若 n 奇且 $f \in C^{n+1}[a,b]$，则

$$\boxed{\int_a^b f(x)\,dx = \sum_{i=0}^{n} a_i f(x_i) + \frac{h^{n+2} f^{(n+1)}(\xi)}{(n+1)!} \int_{-1}^{n+1} t(t-1)\cdots(t-n)\,dt}$$

7. 常见开型 Newton–Cotes 公式（系数也很常考）

这里的积分区间通常写成 $\int_{x_{-1}}^{x_{n+1}}$。

(1) $n=0$：Midpoint Rule（中点法）

$$\boxed{\int_{x_{-1}}^{x_1} f(x)\,dx = 2h\,f(x_0) + \frac{h^3}{3} f''(\xi), \quad x_{-1} < \xi < x_1}$$

(2) $n=1$：两点开型

$$\boxed{\int_{x_{-1}}^{x_2} f(x)\,dx = \frac{3h}{2}\big[f(x_0)+f(x_1)\big] + \frac{3h^3}{4} f''(\xi)}$$

(3) $n=2$：三点开型

$$\boxed{\int_{x_{-1}}^{x_3} f(x)\,dx = \frac{4h}{3}\big[2f(x_0)-f(x_1)+2f(x_2)\big] + \frac{14h^5}{45} f^{(4)}(\xi)}$$

(4) $n=3$：四点开型

$$\boxed{\int_{x_{-1}}^{x_4} f(x)\,dx = \frac{5h}{24}\big[11f(x_0)+f(x_1)+f(x_2)+11f(x_3)\big] + \frac{95}{144} h^5 f^{(4)}(\xi)}$$

8. 做题速用清单（你写作业/考试时的步骤）

1. 选规则：梯形 / Simpson / 闭型NC / 开型NC
2. 确认节点数 n 与步长 h（尤其注意：闭型 $h=(b-a)/n$，开型 $h=(b-a)/(n+2)$）
3. 列出节点 x_i
4. 代入系数求 $\sum a_i f(x_i)$
5. 若要误差：写出误差阶与主导导数（梯形看 f''，Simpson 看 $f^{(4)}$，更高阶看定理 4.2/4.3）
6. 若问“精度”：用 Definition 4.1 +（多项式检验/线性性判别）

4.4 复合数值积分（Composite Numerical Integration）

1. 为什么要用“复合（Composite）”思想？

- **直接用高阶 Newton–Cotes 在大区间通常不合适**：
  - 大区间上要用高阶插值多项式才能“看起来更准”，但高阶系数难算；
  - 等距节点 + 高阶多项式容易产生振荡（Runge 现象风格），导致整体精度变差。
- **核心思路**：把积分区间 $[a,b]$ 划分成很多小区间，在每个小区间上反复使用低阶公式（梯形/Simpson 等），再把结果相加。

2. 复合 Simpson 公式（Composite Simpson’s Rule）

2.1 网格与记号

- 取 **偶数** n（因为 Simpson 每次覆盖两个小区间）

- 步长：

$$h = \frac{b-a}{n}$$

- 等距节点：

$$x_j = a + jh, \qquad j = 0, 1, \ldots, n$$

2.2 “复合”的结构

把 $[a, b]$ 划分为 n 个小区间，然后对每一对连续小区间

$$[x_{2j-2}, x_{2j}], \quad j = 1, 2, \ldots, \frac{n}{2}$$

分别应用一次 Simpson，再把结果相加。

3. Theorem 4.4：复合 Simpson + 误差项

3.1 公式本体（一定要会写）

若 $f \in C^4[a, b]$，n 为偶数，存在 $\mu \in (a, b)$ 使得：

$$\boxed{\int_a^b f(x)\,dx = \frac{h}{3}\left[f(x_0) + 2\sum_{j=1}^{\frac{n}{2}-1} f(x_{2j}) + 4\sum_{j=1}^{\frac{n}{2}} f(x_{2j-1}) + f(x_n)\right] - \frac{b-a}{180}h^4 f^{(4)}(\mu)}$$

3.2 误差阶的理解：为什么是 $O(h^4)$?

- **单次 Simpson**（标准 Simpson）在一个长度 $2h$ 的区间上的局部误差是 $O(h^5)$；
- **复合 Simpson**把区间分成大约 $\frac{n}{2}$ 段（每段长度 $2h$）：
  - “总误差”大致像：$\frac{n}{2} \cdot O(h^5) = O(nh^5)$
  - 又因为 $n \approx \frac{b-a}{h}$，所以 $O(nh^5) = O((b-a)h^4)$
  - 因而整体误差阶写作 $O(h^4)$。

3.3 “复合 Simpson vs 标准 Simpson”的差距（你之前问过的点）

- 标准 Simpson 的误差形式常写成 $O(h^5)$，但它的 h 是固定为

  $$h = \frac{b-a}{2}$$

  你没法通过“增大 n”来继续减小 h。
- 复合 Simpson 中

  $$h = \frac{b-a}{n}$$

  你可以通过增大（偶数）n **显著减小** h，因此整体可做到更高精度。

4. Theorem 4.5：复合梯形公式（Composite Trapezoidal Rule）

4.1 公式 + 误差项

对 $f \in [a, b]$（课件给出误差形式需要 f''），令 $h = \frac{b-a}{n}$，$x_j = a + jh$，
存在 $\mu \in (a, b)$ 使得：

$$\boxed{\int_a^b f(x)\,dx = \frac{h}{2}\left[f(x_0) + 2\sum_{j=1}^{n-1} f(x_j) + f(x_n)\right] - \frac{b-a}{12}h^2 f''(\mu)}$$

4.2 两个关键对比点

- 复合梯形的误差阶是 $O(h^2)$（比复合 Simpson 的 $O(h^4)$ 低）
- 梯形每次只需要 1 个小区间，所以 n **可奇可偶**（比 Simpson 更自由）

5. 舍入误差稳定性（Round-Off Error Stability）

5.1 直觉 vs 事实

直觉：分割更多 $\Rightarrow$ 计算更多 $\Rightarrow$ 舍入误差更大。
课件强调：**复合积分法具有“舍入误差稳定性”**——舍入误差上界 **不依赖于 n（或 h）**。

5.2 以复合 Simpson 为例（课件推导的核心结果）

假设在每个节点 x_i 上，函数值计算有舍入误差：

$$f(x_i) = \tilde{f}(x_i) + e_i, \qquad |e_i| \le \varepsilon$$

复合 Simpson 的“误差传播”形式：

$$e_h = \frac{h}{3}\left[e_0 + 2\sum_{j=1}^{\frac{n}{2}-1} e_{2j} + 4\sum_{j=1}^{\frac{n}{2}} e_{2j-1} + e_n\right]$$

取上界并用 $|e_i| \le \varepsilon$：

$$|e_h| \le (b-a)\varepsilon$$

注意：右侧与 h、n 无关
$\Rightarrow$ 即便为了精度增大 n，舍入误差也不会“因为计算次数更多”而恶化。

5kj.3 与数值微分对比（重要记忆点）

- 数值微分需要除以 h 或 h^2 等：h 很小时舍入误差会被放大，常出现“不稳定”；
- 数值积分这里反而表现为：**当 $h \to 0$，方法仍稳定**。

8. 小结：怎么选方法？

- 若 f 足够光滑且允许 n 取偶数：
  ✅ **优先复合 Simpson（误差阶 $O(h^4)$，通常更省计算）**
- 若只能用端点、或不方便保证 n 为偶数：
  ✅ 复合梯形（误差阶 $O(h^2)$，实现简单）
- 工程习惯：先用误差上界估 n 的量级，再逐步加密网格验证收敛。

（补充：课件提到但未展开）复合中点公式 Composite Midpoint

> 课件在提到“Trapezoidal 与 Midpoint 的扩展”时说明未给出证明。常见结论是：

若把每个小区间 $[x_{j-1}, x_j]$ 的中点记为 $m_j = \frac{x_{j-1}+x_j}{2}$，则

$$\int_a^b f(x)\,dx \approx h\sum_{j=1}^{n} f(m_j), \qquad E_M(f) = -\frac{b-a}{24}h^2 f''(\mu)$$

它同样是 $O(h^2)$，但常数一般比梯形更小（具体优劣依函数而定）。